

Chương 5: Phân Lớp Ảnh (Image Classification)


Tiết 9/9: Phân lớp ảnh có giám sát & Thuật toán K-Hàng xóm gần nhất (KNN)

Môn học: Thị giác máy tính (INFO3111)

Giảng viên: Trần Thành Thắng

Lớp: IT23M

Mục tiêu bài học



Tư duy Quy trình (Pipeline)

Hiểu rõ vòng đời của một bài toán phân loại ảnh có giám sát (Supervised Learning).



Cơ chế Thuật toán (KNN & BoF)

Giải mã nguyên lý học lười của KNN và cách mô hình Bag-of-Features (BoF) chuẩn hóa dữ liệu ảnh.



Triển khai Thực tế (Kỹ năng)

Cài đặt thành thạo bộ phân loại KNN sử dụng thư viện Scikit-learn trong Python.

Quy trình Phân lớp ảnh Có giám sát

Mô hình được dạy thông qua dữ liệu đã gán nhãn trước khi đối mặt với dữ liệu thực tế.

1. Dữ liệu Đầu vào (Input)

- Tập hợp các cặp: (Vector đặc trưng, Nhãn lớp).
- Ví dụ: Đặc trưng HOG + Nhãn Người/Không phải người.

2. Giai đoạn Huấn luyện (Training)

- Mô hình phân tích và học mối liên hệ toán học giữa vector và nhãn.

3. Giai đoạn Dự đoán (Prediction)

- Áp dụng kiến thức để gán nhãn cho các bức ảnh mới.
- Mục tiêu: Tối đa hóa sự chính xác so với nhãn thực tế.

Ví dụ Thực tế: Chuỗi trích xuất đặc trưng và phát hiện đối tượng



Thuật toán K-Hàng xóm gần nhất (KNN)

Đơn giản, trực quan và dựa trên sự tương đồng không gian.




Giả định Cốt lõi: Một đối tượng có khả năng rất cao thuộc về cùng một lớp với các hàng xóm nằm sát nó nhất trong không gian đặc trưng.



Triết lý Học Lười (Lazy Learning):

- Không xây dựng mô hình toán học tường minh trong quá trình huấn luyện.
- Dời toàn bộ khối lượng tính toán sang giai đoạn dự đoán.

Sự Tương Đồng Không Gian




Cơ chế hoạt động 2 giai đoạn của KNN



1. Giai đoạn Học (Lưu trữ)

- **Hành động:** Thuật toán chỉ đơn giản là ghi nhớ.
- **Cơ chế:** Lưu toàn bộ tập dữ liệu huấn luyện (Vector + Nhãn) vào bộ nhớ RAM.
- **Chi phí:** Thời gian cực nhanh (gần như $O(1)$), tốn nhiều dung lượng lưu trữ.



2. Giai đoạn Dự đoán (Xử lý)


Khi có điểm dữ liệu mới xuất hiện:

1. **Tính khoảng cách:** Đo khoảng cách từ điểm mới đến tất cả các điểm trong kho.
2. **Tìm K láng giềng:** Lọc ra K điểm có khoảng cách nhỏ nhất.
3. **Bỏ phiếu đa số:** Gán nhãn cho điểm mới dựa trên nhãn chiếm đa số trong K láng giềng đó.

Nghệ thuật chọn Siêu tham số K


Hiệu năng của mô hình phụ thuộc hoàn toàn vào giá trị K.

K Quá Nhỏ (VD: K=1)



- **Hiện tượng:** Quá khớp (Overfitting).
- **Đặc điểm:** Biên quyết định cực kỳ phức tạp và răng cưa.
- **Hậu quả:** Rất nhạy cảm với nhiễu (noise) trong dữ liệu.

K Quá Lớn




- **Hiện tượng:** Dưới khớp (Underfitting).
- **Đặc điểm:** Ranh giới giữa các lớp bị mượt hóa quá mức.
- **Hậu quả:** Đánh mất các chi tiết phân loại quan trọng.

Giải pháp: Sử dụng kỹ thuật Kiểm chứng chéo (Cross-validation) để thử nghiệm và tìm ra giá trị K tối ưu nhất.

Các Độ đo Khoảng cách (Distance Metrics)


Làm sao để máy tính định lượng sự gần gũi?

Euclidean (L2)




- **Hình học:** Đường chim bay (đường thẳng nối 2 điểm).
- **Đặc điểm:** Phổ biến nhất cho không gian liên tục đa chiều.
- **Trực quan:** Tam giác vuông Pythagore.

Manhattan (L1)



- **Hình học:** Khoảng cách đi theo dạng lưới.
- **Đặc điểm:** Tổng chênh lệch tuyệt đối giữa các tọa độ.
- **Trực quan:** Đường đi ziczac trên bàn cờ hoặc bản đồ đường phố vuông góc.

Minkowski (L-p)



- **Hình học:** Dạng tổng quát của không gian vector.
- **Đặc điểm:** Công thức mẹ bao hàm cả Euclidean ($p=2$) và Manhattan ($p=1$).
- **Trực quan:** Sự biến đổi của hình dáng không gian theo bậc p .

Đánh giá Thuật toán KNN: Ưu điểm & Thách thức

Ưu điểm - Thế mạnh

- ✓ **Trực quan & Dễ hiểu:** Không cần toán học tối ưu hóa phức tạp.
- ✓ **Huấn luyện siêu tốc (Lazy):** Không tốn thời gian xây dựng mô hình ban đầu.
- ✓ **Linh hoạt:** Cập nhật thêm dữ liệu mới vào hệ thống dễ dàng mà không phải train lại từ đầu.
- ✓ **Tiệm cận tối ưu:** Rất chính xác nếu sở hữu tập mẫu dữ liệu đủ lớn.

Thách thức - Nhược điểm

- ⚠ **Chậm khi Dự đoán:** Phải quét toàn bộ database cho mỗi bức ảnh mới.
- ⚠ **Tốn bộ nhớ (RAM):** Bắt buộc phải lưu giữ toàn bộ dữ liệu huấn luyện.
- ⚠ **Lời nguyền số chiều (Curse of Dimensionality):** Khi vector ảnh có quá nhiều chiều (hàng ngàn pixel), khái niệm khoảng cách mất đi ý nghĩa và cực kỳ nhạy cảm với nhiễu.


Tầm quan trọng của Chuẩn hóa Dữ liệu (Feature Scaling)

Bảo vệ khoảng cách khỏi sự chênh lệch tỷ lệ.

Vấn đề: Sự áp đảo của biên độ

Khoảng cách Euclidean rất nhạy cảm với biên độ dữ liệu.


Nếu Đặc trưng A có dải $[0 - 255]$ và Đặc trưng B có dải $[0.0 - 1.0]$, sự thay đổi của A sẽ áp đảo hoàn toàn giá trị khoảng cách, khiến B trở nên vô nghĩa.



Giải pháp: Chuẩn hóa không gian

- **Min-Max Scaling:** Đưa mọi đặc trưng về cùng một dải giá trị (vd: 0 đến 1).
- **Standardization:** Chuẩn hóa theo phân phối chuẩn (Trung bình = 0, Độ lệch chuẩn = 1).

Kết quả: Mọi đặc trưng đều có tiếng nói ngang nhau trong quá trình bỏ phiếu.



Triển khai Thực tế với Scikit-learn

Cài đặt KNN chỉ với 3 dòng lệnh cốt lõi.

```
1 from sklearn.neighbors import
  KNeighborsClassifier
2
3 # 1. Khởi tạo
4 knn = KNeighborsClassifier(n_neighbors=5)
5
6
7 # 2. Huấn luyện (Lưu trữ dữ liệu)
8 knn.fit(X_train, y_train)
9
10 # 3. Dự đoán
11 y_pred = knn.predict(X_new_image)
```

- 1 Khởi tạo Mô hình:** Lựa chọn số lượng láng giềng (K).
- 2 Fit (Học dữ liệu):** Nạp ma trận đặc trưng (X_train) và vector nhãn (y_train) vào bộ nhớ.
- 3 Predict (Dự đoán):** Tính toán và trả về nhãn cho dữ liệu mới.

Lưu ý Tiền xử lý: Toàn bộ X_train và X_new phải là các vector đặc trưng đã được chuẩn hóa (Scaling) và có kích thước nhất quán.

Nút thắt Dữ liệu: Bài toán Kích thước Vector

Tại sao các đặc trưng cục bộ chưa thể dùng ngay cho KNN?

Thực tế Hình ảnh:



Các bộ mô tả như SIFT hay SURF tạo ra số lượng điểm đặc trưng khác nhau cho mỗi bức ảnh (ảnh chi tiết có 1000 điểm, ảnh trơn có 100 điểm).



Không
tương thích

Yêu cầu của Phân lớp (KNN/SVM):



1x128
array slot
(cố định)

Thuật toán máy học bắt buộc đầu vào phải là một **vector duy nhất** có kích thước **cố định**.

Giải pháp: Mô hình Bag-of-Features (BoF)

Lấy cảm hứng từ Xử lý ngôn ngữ tự nhiên (NLP), BoF nén hàng nghìn descriptor rời rạc thành một vector đại diện duy nhất cho toàn bộ ảnh.

Bag-of-Features Bước 1: Xây dựng Từ điển Thị giác

Bag-of-Features Bước 1: Xây dựng Từ điển Thị giác

1. Gom dữ liệu:


Tập hợp hàng triệu vector đặc trưng cục bộ (descriptors) từ toàn bộ tập ảnh huấn luyện vào chung một không gian lớn.

2. Phân cụm K-Means:

Sử dụng thuật toán phân cụm để nhóm các vector có độ tương đồng cao lại với nhau thành K cụm riêng biệt.


3. Định nghĩa Từ Vựng (Visual Words):

- Tâm của mỗi cụm (Centroid) chính là một Từ vựng thị giác.
- Tập hợp K tâm cụm này tạo thành một Từ điển thị giác (Codebook) chuẩn mực dùng để đối chiếu.



Bag-of-Features Bước 2: Biểu diễn bằng Histogram

Chuyển đổi hình ảnh thành tần suất xuất hiện.



Quy trình Lượng hóa (Quantization):

- Trích xuất các đặc trưng cục bộ của một bức ảnh mới.
- Đối chiếu từng đặc trưng với Từ điển thị giác, gán nó cho Từ vựng (tâm cụm) có khoảng cách gần nhất.

Tạo Histogram (Vector Cố định):

- Đếm số lần xuất hiện của từng từ vựng trong ảnh.
- Kết quả thu được là một Biểu đồ tần suất (Histogram) có chiều dài chính xác bằng K.
- **Đột phá:** Bức ảnh giờ đây là một vector kích thước cố định, hoàn hảo để đưa vào KNN!

Tổng kết Pipeline & Định hướng

Hành trình Phân lớp:

- **1. Đặc trưng Cục bộ:** Trích xuất các điểm ảnh giá trị, bất biến với tỷ lệ và góc nhìn.
- **2. Nén BoF:** Chuyển đổi số lượng điểm biến thiên thành Vector Histogram kích thước cố định.
- **3. Phân loại KNN:** So sánh khoảng cách trong không gian vector và bỏ phiếu gán nhãn.

Chuẩn bị cho Tiết 10: Vượt qua giới hạn của KNN

- Dù KNN trực quan và dễ hiểu, nhưng ranh giới phân loại của nó phụ thuộc cục bộ và cực kỳ tốn tài nguyên tìm kiếm khi dữ liệu lớn.
- Tiết sau, chúng ta sẽ học cách tối đa hóa lề quyết định toàn cục với một thuật toán sắc bén hơn: Máy Vector Hỗ trợ (Support Vector Machine - SVM).

