

Chương 7. Một số mô hình Deep Learning cho Thị giác máy tính

Tiết 1/3 - Sự khởi đầu và sức mạnh của độ sâu mạng

- 7.4. Mô hình AlexNet (Cột mốc lịch sử)
- 7.1. Mô hình VGG16 (Sức mạnh của sự đơn giản)

Bối cảnh: Kỷ nguyên của các Mô hình Tiền huấn luyện (Pretrained Models)



Cuộc thi ILSVRC (ImageNet)

Thử thách phân loại 1.000 lớp đối tượng trên tập dữ liệu hàng triệu hình ảnh lớn.



Sự bứt phá

Trong 6 năm, tỷ lệ lỗi (top-5) giảm mạnh từ hơn 26% xuống dưới 2,3% nhờ sự tiến hóa của mạng CNN.



Ý nghĩa thực tiễn

Các mô hình chiến thắng trở thành kiến trúc nền tảng. Thay vì huấn luyện từ đầu, chúng được tái sử dụng làm bộ trích xuất đặc trưng qua kỹ thuật Học chuyển giao (Transfer Learning).


7.4. Mô hình AlexNet (2012)

Tác giả: Alex Krizhevsky, Ilya Sutskever và Geoffrey Hinton.

Thành tựu: Vô địch ILSVRC 2012 với tỷ lệ lỗi áp đảo 17% (đối thủ thứ 2 là 26%).

Đặc điểm kiến trúc:

- Kế thừa mạng LeNet-5 cổ điển nhưng quy mô lớn và sâu hơn.
- Bước ngoặt: Kiến trúc đầu tiên xếp chồng trực tiếp các lớp tích chập (convolutional layers) lên nhau, thay vì bắt buộc xen kẽ một lớp gộp (pooling) sau mỗi lớp tích chập.



Các kỹ thuật đột phá trong AlexNet




Hàm ReLU

Tránh bão hòa Gradient.
Thay thế Sigmoid/Tanh để
tăng tốc độ hội tụ.




Dropout (50%)

Áp dụng tại lớp kết nối đầy đủ
(F9, F10). Vô hiệu hóa ngẫu
nhiên nơ-ron để giảm hiện
tượng Quá khớp (Overfitting).



Data Augmentation

Dịch chuyển, lật ngang và
thay đổi ánh sáng ảnh để mô
hình tổng quát hóa tốt hơn.



Chuẩn hóa (LRN)

Chuẩn hóa phản hồi cục bộ.
Tạo sự kích hoạt cạnh tranh,
giúp các bản đồ đặc trưng
chuyên biệt hóa.


7.1. Mô hình VGGNet (2014)

Tác giả: Karen Simonyan và Andrew Zisserman (Nhóm VGG, Đại học Oxford).

Thành tựu: Á quân thử thách ILSVRC 2014.

Đặc điểm kiến trúc:

- Kiến trúc cổ điển, cực kỳ đơn giản và mạch thẳng.
- Xếp chồng liên tiếp 2 hoặc 3 lớp tích chập rồi mới đến 1 lớp gộp (đạt độ sâu 16 hoặc 19 lớp).
- Điểm nhấn: Chỉ sử dụng bộ lọc (kernel) kích thước siêu nhỏ 3 x 3, nhưng số lượng bộ lọc rất lớn.
- Ứng dụng: Mạng trích xuất đặc trưng mạnh mẽ trong Transfer Learning dù khối lượng tính toán lớn.



Phân tích chi tiết Kiến trúc VGG16

Tổng số lớp


16 lớp có trọng số (13 lớp Convolutional + 3 lớp Fully Connected).

Cấu trúc dạng khối (Blocks)

Chia làm 5 khối. Kết thúc mỗi khối là lớp Max Pooling 2 x 2 (stride 2) để giảm một nửa không gian.


Sự gia tăng bộ lọc

Số lượng kênh nhân đôi sau mỗi lớp gộp: $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$, tăng cường năng lực trích xuất đặc trưng phức tạp.



Sức mạnh của bộ lọc nhỏ 3 x 3 trong VGG

VGG từ bỏ hoàn toàn bộ lọc lớn (11 x 11, 5 x 5) của AlexNet để tối ưu hóa Vùng cảm nhận (Receptive Field).



Xếp chồng 2 lớp 3 x 3 $\approx$ Vùng cảm nhận của 1 lớp 5 x 5. (Xếp chồng 3 lớp $\approx$ 7 x 7).

Tăng tính phi tuyến

Nhiều lớp tích chập nhỏ cho phép chèn nhiều hàm ReLU hơn $\rightarrow$ Học biểu diễn phức tạp và có tính phân biệt cao.

Giảm tham số


Số lượng trọng số cần huấn luyện ít hơn so với việc dùng một bộ lọc lớn tương đương.

Thách thức của VGG: Bùng nổ Tham số và Tính toán



Khối lượng tham số khổng lồ

Khoảng 138 triệu tham số (gấp hơn 2 lần AlexNet). Phần lớn tập trung ở các lớp kết nối đầy đủ (FC) cuối mạng.



Chi phí tính toán cao

Đòi hỏi tới 15.3 tỷ phép toán (MACs) cho mỗi lần dự đoán. Gây khó khăn khi triển khai trên thiết bị yếu hoặc yêu cầu thời gian thực.



Độ khó trong huấn luyện

Cấu trúc quá sâu, mạch thẳng khiến mạng khó hội tụ. Tác giả ban đầu phải áp dụng huấn luyện hai bước: huấn luyện mạng nông trước để mượn trọng số khởi tạo.

Tổng hợp: AlexNet vs. VGG16

AlexNet (2012)	VGG16 (2014)	Tiêu chí
8 lớp	16 lớp	Số lớp trọng số
Lớn (11 x 11, 5 x 5)	Siêu nhỏ (3 x 3 đồng nhất)	Kích thước bộ lọc
~60 triệu	~138 triệu	Số lượng tham số
ReLU (Bắt đầu áp dụng)	ReLU (Sử dụng dày đặc)	Hàm kích hoạt
Lớp gộp xen kẽ liên tục	Khối tích chập xếp chồng liên tiếp	Triết lý thiết kế


Nguyên lý Học chuyển giao: Phân cấp đặc trưng

Khi được huấn luyện trên ImageNet, mô hình học được hệ thống bộ phát hiện đặc trưng phân cấp cực kỳ mạnh mẽ.




Lớp cao (High-level):

Học các đặc trưng phức tạp mang tính đặc thù của đối tượng (mắt chó, bánh xe, cánh hoa).



Lớp giữa (Mid-level):

Kết hợp các đường nét thành các hình khối, họa tiết đơn giản.



Lớp thấp (Low-level):

Học cấu trúc cơ bản như góc, cạnh, màu sắc, đường nét. Mang tính phổ quát cho mọi hình ảnh.

Ứng dụng VGG16 & AlexNet trong thực tiễn



Tính ổn định cao

Dù chi phí tính toán lớn, các đặc trưng do VGG16 trích xuất có tính ổn định và tính phân biệt cực kỳ xuất sắc. Không ai huấn luyện lại VGG16 từ con số 0; chúng ta kế thừa bộ trọng số đã được tối ưu hóa trên siêu máy tính.



Keras Applications

Các thư viện Deep Learning hiện đại cung cấp sẵn kiến trúc VGG16 với bộ trọng số 'imagenet'. Cho phép tải và tái sử dụng trực tiếp làm Mạng xương sống (Backbone) chỉ bằng một vài dòng code.


Triển khai Transfer Learning với VGG16

1. Tải Base Model




Gọi VGG16 và cấu hình tải trọng số chuẩn (weights='imagenet').

2. Cắt bỏ phần đầu



Lệnh `include_top=False` bỏ qua các lớp Fully Connected ở đỉnh mạng. Chỉ giữ lại phần thân trích xuất đặc trưng.

3. Thiết kế Đầu phân loại mới



- Thêm lớp `GlobalAveragePooling2D` chuyển bản đồ đặc trưng thành mảng 1D.
- Thêm lớp `Dense` (Hàm `Softmax`) với số nơ-ron bằng số lớp của bài toán mới.

Giai đoạn 1: Đóng băng trọng số (Freezing Layers)

Khái niệm:

Khóa các trọng số của mô hình cơ sở (VGG16) để chúng không bị thay đổi trong quá trình huấn luyện đầu tiên.

Mục đích cốt lõi:

- Giữ nguyên vẹn tri thức đã học từ dữ liệu khổng lồ.
- Thuật toán hạ gradient chỉ tập trung cập nhật các trọng số mới được khởi tạo ngẫu nhiên ở lớp phân loại (Head) trên cùng.
- Đảm bảo hội tụ nhanh, tiết kiệm tài nguyên và tránh hiện tượng quá khớp (overfitting).



```
layer.trainable = False
```


Giai đoạn 2: Tinh chỉnh (Fine-Tuning)

Khái niệm:

Sau khi lớp Head mới đã ổn định, mở khóa (unfreeze) một vài lớp tích chập ở tầng cao nhất của VGG16 và tiếp tục huấn luyện toàn bộ.

Mục đích:

Cho phép các bộ lọc đặc trưng cấp cao tự điều chỉnh nhẹ để thích ứng sâu hơn với những đặc thù riêng của tập dữ liệu mới.



```
layer.trainable = True  
(Cho các lớp trên cùng)
```



Lưu ý cực kỳ quan trọng: Bắt buộc phải giảm tốc độ học (learning rate) xuống mức rất nhỏ. Gradient lớn sẽ làm hỏng và phá hủy các trọng số tinh tế đã được mượn từ mô hình tiền huấn luyện.

Tổng kết Tiết 1

AlexNet (2012)

Cột mốc khởi đầu kỷ nguyên Deep Learning hiện đại. Khẳng định sức mạnh của mạng CNN sâu kết hợp ReLU và Dropout.

VGG16 (2014)

Tiên phong thiết kế mạng dạng khối đồng nhất. Chứng minh sức mạnh biểu diễn khổng lồ của việc xếp chồng liên tiếp các bộ lọc siêu nhỏ 3×3 .

Thực tiễn

Dù nặng về tính toán, VGG16 là backbone kinh điển. Kết hợp cùng Transfer Learning (Đóng băng & Tinh chỉnh), nó giải quyết hoàn hảo bài toán thiếu dữ liệu.



→ **Hành trình tiếp theo (Tiết 2/3):** Khám phá sự đột phá về thiết kế đa tỷ lệ (Inception V3) và giải quyết lỗi triệt tiêu đạo hàm cho mạng cực sâu (ResNet).