



KIẾN TRÚC MẠNG NƠ-RON TÍCH CHẬP (CNN) HIỆN ĐẠI (Tiết 2/3)


Kỷ nguyên của Mạng Sâu: Sự tiến hóa từ
GoogLeNet, ResNet đến Xception và SENet

Tăng cường Dữ liệu (Data Augmentation)

- **Định nghĩa:** Tạo ra các biến thể thực tế từ dữ liệu gốc (dịch chuyển, xoay, lật, độ tương phản).
- **Mục đích:** Kỹ thuật điều chuẩn mạnh mẽ, tăng kích thước tập huấn luyện để giảm thiểu quá khớp (overfitting).

Khắc phục Mất cân bằng: Kỹ thuật SMOTE

- **Vấn đề:** Tập dữ liệu mất cân bằng làm sai lệch trọng số.
- **Giải pháp:** Sinh mẫu thiểu số tổng hợp (SMOTE) tạo thêm mẫu nhân tạo cho các lớp ít xuất hiện.




Hình 1. Quá trình sinh các mẫu huấn luyện mới từ hình ảnh gốc thông qua Data Augmentation.

Mô-đun Inception: Đột phá mở rộng chiều ngang

Cấu trúc Đa đường (Multi-path): Tín hiệu đầu vào được đưa qua 4 lớp song song.

Nắm bắt Đa tỷ lệ: Kích thước kernel đa dạng cho phép trích xuất các mẫu (patterns) ở nhiều tỷ lệ hình ảnh khác nhau.

Nối theo Chiều sâu: Các bản đồ đặc trưng từ 4 nhánh được xếp chồng lại dọc theo chiều sâu thành đầu ra tổng hợp.



Hình 2. Cấu trúc một mô-đun Inception tiêu chuẩn với các nhánh song song.

Động lực thiết kế: Sức mạnh của Tích chập 1×1

Việc sử dụng bộ lọc 1×1 phục vụ 3 mục đích toán học cốt lõi trong mạng kiến trúc:



Nắm bắt Đặc trưng Chiều sâu

Chụp lại các mẫu phân bố dọc theo chiều sâu (thông tin xuyên kênh - cross-channels) thay vì đặc trưng không gian.



Lớp Thắt nút cổ chai (Bottleneck)

Xuất ra số lượng bản đồ đặc trưng ít hơn đầu vào. Giảm mạnh số chiều, cắt giảm chi phí tính toán và tham số.



Tăng cường Sức mạnh Biểu diễn


Mỗi cặp tích chập (ví dụ: [1×1, 3×3]) tương đương với việc quét một mạng nơ-ron hai lớp qua hình ảnh thay vì một lớp tuyến tính đơn thuần.

Kiến trúc Tổng thể GoogLeNet

Ngăn xếp Inception: 9 mô-đun Inception xếp chồng lên nhau, xen kẽ các lớp gộp (pooling) để giảm không gian.

Bộ Phân loại Phụ (Auxiliary Classifiers): Cắm vào giữa mạng để chống lại hiện tượng triệt tiêu đạo hàm và hỗ trợ điều chuẩn.

Gộp Trung bình Toàn cục (GAP): Loại bỏ các lớp kết nối đầy đủ khổng lồ. Tính trung bình từng bản đồ đặc trưng để hạn chế quá khớp.



Hình 3. Sơ đồ kiến trúc GoogLeNet.

Thách thức của Mạng CNN Siêu Sâu: Bài toán Tối ưu hóa

Độ sâu tạo ra rào cản toán học nghiêm trọng ngăn cản mô hình hội tụ.



Biểu hiện (Symptom)

Nghịch lý độ sâu: Thử nghiệm thực tế cho thấy mạng 34 lớp có tỷ lệ lỗi cao hơn mạng 18 lớp cùng cấu trúc. Không phải do quá khớp, mà do tối ưu hóa thất bại.



Vấn đề (Problem)

Triệt tiêu Đạo hàm (Vanishing Gradients): Đạo hàm nhỏ dần khi lan truyền ngược. Trọng số lớp đầu không được cập nhật khiến mạng không hội tụ.



Nhu cầu (Need)

Cơ chế mới: Cần một thiết kế kiến trúc cho phép tín hiệu gradient đi xuyên qua hàng trăm lớp mạng một cách mượt mà, không suy giảm.


ResNet: Khái niệm Học Thặng dư (Residual Learning)

Nhà vô địch ILSVRC 2015 với mạng sâu 152 lớp, sai số top-5 dưới 3.6%.

Cơ chế Toán học

- **Kết nối Tắt (Skip Connections):** Tín hiệu đầu vào $\mathbf{x}$ được cộng trực tiếp vào đầu ra của lớp cao hơn.
- Thay vì học toàn bộ hàm $\mathbf{h}(\mathbf{x})$, mạng bị ép học hàm thặng dư:

$$f(\mathbf{x}) = h(\mathbf{x}) - \mathbf{x}$$




Lợi ích Tối ưu

- **Khởi tạo Nhận dạng:** Ban đầu, mạng xuất ra bản sao của đầu vào (identity function).
- **Đường cao tốc Gradient:** Luồng tín hiệu truyền đi cực nhanh, lan truyền ngược không bị suy giảm qua các lớp phi tuyến tính.

Hình 4. Cơ chế Học thặng dư với Kết nối tắt.


Sức mạnh của Khối Thặng dư (Residual Unit)

Mạng Sâu Tiêu chuẩn




- **Cơ chế:** Khi một lớp 'chết' hoặc chưa học được đặc trưng, nó sẽ chặn toàn bộ luồng lan truyền ngược.
- **Hậu quả:** Các lớp bên dưới không nhận được gradient, quá trình học dừng lại.

Mạng Thặng dư (ResNet)



- **Cơ chế:** Mỗi Khối thặng dư (RU) gồm 2 lớp tích chập (3x3), Batch Normalization và ReLU.
- **Ưu điểm:** Nhờ kết nối tắt, tín hiệu vượt qua các lớp chết. Chống chặn gradient hoàn hảo.

Kiến trúc ResNet-34 & Xử lý sai lệch kích thước



Hình 5. Kết nối tắt xử lý khi thay đổi kích thước tensor.


Cấu trúc: Đoạn giữa của ResNet-34 là một ngăn xếp Khối thẳng dư cực sâu.

Vấn đề Sai lệch Kích thước: Sau mỗi vài module, số bản đồ đặc trưng tăng gấp đôi, không gian giảm một nửa (stride 2). Kích thước đầu vào và đầu ra không khớp, không thể cộng trực tiếp.

Giải pháp: Áp dụng lớp tích chập 1x1 có stride = 2 trực tiếp trên đường kết nối tắt (nhánh đứt đoạn trong hình) để ép kích thước đầu vào khớp hoàn toàn với đầu ra.

Xception: Tích chập Tách biệt theo Chiều sâu

Thay thế hoàn toàn mô-đun Inception bằng Depthwise Separable Convolutions (F. Chollet, 2016).



Hình 6. Lớp tích chập tách biệt theo chiều sâu.

- **Động lực:** Tách biệt hoàn toàn việc học mẫu không gian (spatial patterns) và mẫu xuyên kênh (cross-channel).
- **Bước 1 - Depthwise (Không gian):** Áp dụng duy nhất một bộ lọc không gian độc lập cho từng kênh đầu vào riêng lẻ.
- **Bước 2 - Pointwise (Xuyên kênh):** Sử dụng tích chập 1×1 tiêu chuẩn để trộn và kết hợp các kênh lại với nhau.
- **Kết quả:** Giảm đáng kể số lượng tham số và khối lượng tính toán nhưng vẫn tăng độ chính xác tổng thể.

Sự kết hợp & Tiến hóa: Inception-ResNet

Tối ưu hóa đa chiều để phá vỡ các giới hạn kiến trúc

GoogLeNet (Inception)

Thế mạnh: Khai thác chiều ngang. Trích xuất đặc trưng đa tỷ lệ hiệu quả nhờ các nhánh tích chập song song song song. Tối ưu hóa tham số cục bộ.

+

ResNet

Thế mạnh: Khai thác chiều sâu. Kết nối tắt (Skip Connections) tạo đường truyền mượt mà cho gradient, khắc phục rào cản tối ưu hóa.

=


Inception-v4 / Inception-ResNet

Thành tựu: Tỷ lệ lỗi top-5 ImageNet giảm xuống sát mức 3%. Tốc độ hội tụ nhanh hơn đáng kể so với mạng Inception thuần túy.

Chú ý & Hiệu chỉnh: Mạng SENet (Squeeze-and-Excitation)

Vô địch ILSVRC 2017 (2.25% error). Không phải là một mạng mới, mà là một mô-đun “cắm thêm” vô cùng linh hoạt.

Khả năng Tương thích:
Đính kèm một Khối SE nhỏ gọn vào mọi mô-đun Inception hoặc ResNet hiện có để tạo thành SE-Inception và SE-ResNet.



Hình 7. Khối SE đính kèm vào Inception (trái) và ResNet (phải).

Triết lý Chú ý (Attention):
Bỏ qua không gian, chỉ tập trung phân tích dọc theo chiều sâu (depth) của bản đồ đặc trưng.

Khám phá Tương quan:
Mạng tự học xem các đặc trưng nào thường xuất hiện cùng nhau, từ đó tự động đánh giá lại mức độ quan trọng của từng kênh.


Giải phẫu Hệ thống: Cấu trúc cốt lõi của Khối SE

Khối SE là một "**vi mạng**" (micro-network) hoạt động nội bộ, gồm 3 lớp cơ bản:

1. Gộp trung bình toàn cục (Global Average Pooling): Tính toán mức độ kích hoạt trung bình cho toàn bộ từng bản đồ đặc trưng đầu vào.

2. Lớp Ẩn (Dense) + ReLU [Nén/Squeeze]: Số lượng nơ-ron giảm mạnh (ví dụ **1/16**). Ép dữ liệu thành vector nhúng đại diện cho phân phối đặc trưng tổng quát.


3. Lớp Đầu ra (Dense) + Sigmoid [Kích thích/Excitation]: Xuất ra một vector 'Hiệu chỉnh' với mỗi giá trị nằm trong khoảng từ 0 đến 1.



Hình 8. Vi mạng bên trong một Khối Squeeze-and-Excitation.


Cơ chế Hoạt động của Khối SE

Chu trình định chuẩn lại tầm quan trọng của các đặc trưng.



Hình 9. Lưu đồ Khối SE thực hiện hiệu chỉnh lại bản đồ đặc trưng.

BƯỚC 1: Squeeze (Nén)



Nén thông tin không gian của mỗi bản đồ đặc trưng thành một vector chiều thấp duy nhất. Buộc mạng học một biểu diễn tổng quát về sự kết hợp giữa các kênh.

BƯỚC 2: Excitation (Kích thích)



Vector đi qua các lớp Dense và hàm Sigmoid để sinh ra một vector hiệu chỉnh (recalibration vector) chứa các giá trị tỷ lệ từ 0 đến 1.

BƯỚC 3: Recalibration (Hiệu chỉnh lại)



Các bản đồ gốc được nhân chập với vector hiệu chỉnh. Đặc trưng quan trọng (điểm gần 1) được **Tăng cường**. Đặc trưng nhiều/không liên quan bị **Bóp nghẹt**.

Tổng kết: Bản Đồ Tiến Hóa Kiến Trúc Mạng CNN

Những tư tưởng cốt lõi định hình kỷ nguyên học sâu hiện đại

Kiến Trúc	Kỹ Thuật Lỗi (Cơ chế)	Triết Lý Thiết Kế (Động lực)
GoogLeNet / Inception	Tích chập đa tỷ lệ song song & Tích chập Bottleneck 1x1.	Mở rộng chiều ngang (wider) hiệu quả hơn thay vì chỉ xếp chồng chiều sâu.
ResNet	Kết nối tắt (Identity Skip Connections).	Vượt qua rào cản tối ưu hóa (triệt tiêu đạo hàm) để đẩy độ sâu lên mức cực đại.
Xception	Tích chập tách biệt theo chiều sâu (Depthwise Separable Convolutions).	Tách rời hoàn toàn không gian toán học của đặc trưng không gian và đặc trưng chiều sâu.
SENet	Cơ chế chú ý nhánh (Squeeze-and-Excitation).	Không phân bổ trọng số mù quáng; tự động định hướng sự tập trung vào các đặc trưng hữu ích nhất.