


Chương 7. Một số mô hình Deep Learning cho Thị giác máy tính


Tiết 3/3: Tối ưu hóa cho thiết bị di động & Tổng kết



7.2. Mô hình MobileNet: Thiết kế tinh gọn, hiệu năng cao cho Edge AI.



Học Chuyển Giao (Transfer Learning): Ứng dụng mô hình tiền huấn luyện.



Tổng kết Chương 7: Hành trình tiến hóa của các kiến trúc CNN kinh điển.

Sự dịch chuyển sang Edge Computing

Nguyên lý đánh đổi (Trade-off)



Thách thức: Các mạng CNN kinh điển (**VGG, ResNet**) sở hữu độ chính xác cao nhưng mang nhược điểm chí mạng: **dung lượng khổng lồ** và **chi phí tính toán (FLOPs)** quá lớn. Khả năng **chạy trực tiếp trên thiết bị di động, IoT** hay **Web** là bất thi.




Mục tiêu của MobileNet: Kiến trúc tinh gọn do Google phát triển. Cân bằng tối ưu giữa: **Kích thước mô hình nhỏ (Low Memory Footprint)** và **Tốc độ suy luận nhanh (Low Latency)**.



Triết lý: Chấp nhận hy sinh một phần rất nhỏ độ chính xác để giảm thiểu theo cấp số nhân khối lượng tham số và phép toán.

Tích chập tách biệt chiều sâu (Depthwise Separable Convolution)




Nguyên lý cốt lõi: Tách rời hoàn toàn việc học đặc trưng không gian (spatial patterns) và đặc trưng chéo kênh (cross-channel patterns).

Định lượng Hiệu năng: Tối ưu hóa độ phức tạp

$$\frac{1}{N} + \frac{1}{K^2}$$


Tỷ lệ giảm tính toán.
Khối lượng tính toán được giảm tỷ lệ thuận với K^2 (K là kích thước kernel).

Ví dụ: Bộ lọc 3x3 giảm tính toán từ 8-9 lần so với tiêu chuẩn.
Số tham số chỉ tăng tuyến tính, không tăng bậc hai.




MobileNetV2: Khối thắt cổ chai đảo ngược (Inverted Residuals)

Thiết kế lại hoàn toàn cấu trúc luồng dữ liệu nhằm bảo toàn tối đa thông tin trên đa tập phi tuyến.



Hệ sinh thái Mạng Tinh gọn (Lightweight Networks)


CSPNet



(Cross Stage Partial Network)


Tương tự DenseNet, nhưng phân tách luồng dữ liệu. Một phần đầu vào nối thẳng (concatenate) đến đầu ra, bỏ qua hoàn toàn các phép tính bên trong khối.

ShuffleNet



Bổ sung cơ chế 'trộn kênh' (channel shuffle) giữa các tích chập nhóm. Thông tin giữa các nhóm có thể giao tiếp mà không tăng chi phí tính toán.

SqueezeNet




Sử dụng các module 'Fire' đặc trưng kết hợp với tỷ lệ nén kênh cực cao để giảm thiểu dung lượng bộ nhớ.

Ma trận Quyết định: Lựa chọn Mô hình phù hợp

Không có mạng CNN nào là hoàn hảo tuyệt đối. Việc lựa chọn phụ thuộc vào Ưu tiên và Ràng buộc phần cứng.

Tiêu chí Ràng buộc	Kiến trúc Đề xuất	Lý do cốt lõi
Băng thông/Bộ nhớ (Mobile/IoT)	MobileNet / SqueezeNet	Tối ưu hóa số lượng tham số & phép toán bậc nhất.
Tối đa hóa Độ chính xác	EfficientNet / ResNeXt lớn	Quy luật mở rộng kép (Compound Scaling) cho hiệu năng State-of-the-Art.
Tốc độ thực thi trên CPU	Inception-v3	Các nhánh tính toán song song tối ưu tốt trên kiến trúc đa luồng của CPU.
Tốc độ thực thi trên GPU	Họ ResNet	Luồng dữ liệu thẳng, đồng nhất, cực kỳ nhanh trên tính toán mảng song song (GPU).

EfficientNet: Quy luật Mở rộng Kép (Compound Scaling)



Sử dụng ngân sách tính toán (compute budget) φ . Nếu φ tăng 1, số lượng FLOPs tỷ lệ thuận với 2^φ . Kích thước mạng được tỷ lệ theo công thức: α^φ , β^φ , γ^φ .
Bộ thông số tối ưu từ Grid Search: $\alpha=1.2$, $\beta=1.1$, $\gamma=1.1$ (Họ mô hình B0 đến B7).

Tương quan: Độ chính xác, Tham số & Thời gian Suy luận

Khối lượng tham số cực nhỏ, tốc độ CPU cực nhanh (25.9ms).

Class name	Size (MB)	Top-1 acc	Top-5 acc	Params	CPU (ms)
MobileNetV2	14	71.3%	90.1%	3.5M	25.9
MobileNet	16	70.4%	89.5%	4.3M	22.6
NASNetMobile	23	74.4%	91.9%	5.3M	27.0
EfficientNetB0	29	77.1%	93.3%	5.3M	46.0
EfficientNetB1	31	79.1%	94.4%	7.9M	60.2
EfficientNetB2	36	80.1%	94.9%	9.2M	80.8
EfficientNetB3	48	81.6%	95.7%	12.3M	140.0
EfficientNetB4	75	82.9%	96.4%	19.5M	308.3
InceptionV3	92	77.9%	93.7%	23.9M	42.2
ResNet50V2	98	76.0%	93.0%	25.6M	45.6
EfficientNetB5	118	83.6%	96.7%	30.6M	579.2
EfficientNetB6	166	84.0%	96.8%	43.3M	958.1
ResNet101V2	171	77.2%	93.8%	44.7M	72.7
InceptionResNetV2	215	80.3%	95.3%	55.9M	130.2
EfficientNetB7	256	84.3%	97.0%	66.7M	1578.9

Độ chính xác áp đảo nhờ Compound Scaling.

Ghi chú: Các mô hình lớn hơn thường chính xác hơn, nhưng không phải lúc nào cũng tối ưu phần cứng. Ví dụ: EfficientNetB2 nhỏ gọn hơn InceptionV3 nhưng lại cho độ chính xác cao hơn.

Học Chuyển Giao: Triết lý “Đứng trên vai người khổng lồ”


Vấn đề - From Scratch	Giải pháp - Flowchart Transfer Learning
 Hàng tuần huấn luyện Tập dữ liệu khổng lồ (Hàng triệu ảnh) Huấn luyện từ đầu: Cực kỳ tốn kém & Dễ Overfit	Tập dữ liệu khổng lồ (ImageNet) Pre-trained CNN (Đã huấn luyện) Trích xuất đặc trưng (Feature Extraction) Khóa Feature Extractor (Giữ nguyên trọng số) Bộ phân loại mới Tập dữ liệu nhỏ Giải quyết Tác vụ mới hiệu quả

Kỹ thuật tận dụng mô hình đã được huấn luyện sẵn. Khối trích xuất đặc trưng được giữ lại, mạng nơ-ron chỉ học cách chuyển đổi biểu diễn bậc cao để phân loại dữ liệu mới.

Chiến lược Khai thác Mô hình Tiền huấn luyện


Khối Xám = Trọng số đóng băng (Frozen) |
Khối Đỏ = Trọng số huấn luyện (Trainable)

Đóng băng toàn bộ (Feature Extraction / Freezing)




Khóa toàn bộ trọng số gốc. Chỉ huấn luyện lớp cuối.
Dùng khi dữ liệu mới **RẤT ÍT** nhưng tương đồng cao với dữ liệu gốc.

Tinh chỉnh một phần (Partial Fine-tuning)



Mở khóa một vài lớp tích chập sâu nhất. Cho phép mô hình học các đặc trưng cụ thể.
Dùng khi dữ liệu mới ở mức trung bình.

Tinh chỉnh toàn bộ (Full Fine-tuning)



Mở khóa toàn bộ kiến trúc. Đòi hỏi **tập dữ liệu mới khổng lồ**. Nguy cơ **Overfitting** cực lớn nếu dữ liệu thiếu hụt

Ứng dụng Thực tiễn: Phát hiện Đối tượng (Object Detection)

Mô hình Hai giai đoạn - Faster R-CNN

Ưu tiên: Độ chính xác tối đa. Tập trung vào việc tạo ra các vùng đề xuất chất lượng cao trước khi phân loại.

[Image Input]

[CNN Backbone]

[Mạng đề xuất
vùng (RPN)]

[Bộ phân loại
Bounding Box]

Mô hình Một giai đoạn - SSD / YOLO

Ưu tiên: Nhìn một lần (Look once) & Tốc độ thời gian thực. Dự đoán đồng thời các hộp giới hạn và xác suất lớp trong một lần truyền mạng.

[Image Input]


[CNN Backbone
(e.g., MobileNet)]

[Trực tiếp ra
Vị trí & Nhãn]

SSDLite:

Sự kết hợp hoàn hảo giữa xương sống tinh gọn MobileNetV2 và cơ chế SSD, tối ưu hóa triệt để cho suy luận trên thiết bị di động.

Vòng đời Mô hình: Đưa Deep Learning vào thực tiễn



Câu hỏi Tự đánh giá Kiến thức

1

Phân biệt cơ chế hoạt động và chi phí tính toán giữa Tích chập tiêu chuẩn và Tích chập tách biệt chiều sâu. Sự hy sinh ở đây là gì?

2

Giải thích vai trò của 3 bước trong khối "Thắt cổ chai đảo ngược" của MobileNetV2. Tại sao bước cuối không dùng hàm kích hoạt phi tuyến?

3

Trình bày sự khác biệt cốt lõi giữa quy mô đơn chiều và quy mô mở rộng kép (Compound Scaling) của EfficientNet.

4

Khi nào nên áp dụng chiến lược "Đóng băng trọng số" (Freezing) và khi nào nên "Tinh chỉnh toàn bộ" (Full fine-tuning) trong Học chuyển giao?

Tổng kết: Dấu ấn Lịch sử Kiến trúc CNN

VGG / AlexNet

Khởi nguyên học sâu.
Chứng minh sức mạnh của xếp chồng bộ lọc 3×3 .

ResNet

Đột phá chiều sâu.
Kết nối tắt (Skip Connections) xóa bỏ triệt tiêu đạo hàm, mở ra mạng hàng trăm lớp.

Inception

Tối ưu không gian mạng.
Mô-đun đa nhánh và thắt cổ chai 1×1 .

MobileNet / EfficientNet

Kỷ nguyên Di động & Hiệu năng.
Phân tách chiều sâu tính toán và hệ thống hóa toán học công thức Scale mô hình.

Triết lý Hiện đại: Học Chuyển Giao (Transfer Learning) – Ứng dụng thực tiễn không bắt đầu từ con số 0, mà kế thừa trọng số từ các kiến trúc kinh điển này.